

# スピン波を用いた物理リザーバーコンピューティングによる波形分類

## Waveform classification using spin-wave-based physical reservoir computing

指導教員 廣瀬 明

廣瀬研究室 修士過程 1 年 37-196445 市村 剛大

### Abstract

In recent years, pattern recognition methods such as Deep Learning put into practical use actively, on the other hand their energy consumption is becoming a problem. Physical Reservoir Computing (PRC) is a collecting a lot of attention as a method which realize pattern recognition with low energy consumption. A basic concept of spin-wave based PRC was proposed by author's group. In this research, we investigate the features of this spin-wave based PRC device on the simulation for realizing physical implementation of this device.

This paper reports the characteristics of the spin wave in the garnet film in the physics of propagation, interference and chip-edge scattering/reflection in relation to the neural learning and task functions. First we observe the spin-wave propagation, where we confirm that waves spread anisotropically and interfere nonlinearly. Then we map how information useful for a task distributes in the reservoir. Here the task is sinusoidal / square wave classification. Virtually we assume that every pixel has a reservoir readout connection so that the terminals cover the chip fully and finely. Through the analysis, we visualize the distribution of information on the chip. The result shows that the appropriate size of the output electrodes can be several tens nanometers in its diameter. We also report that the device which has 64 randomly placed output electrodes can well classify input sinusoidal / square waves. Then the structure of this device is realistic enough. We also conduct learning with devices having 8, 16 or 32 electrodes to analyze the relationship between the numbers of the output electrodes and the speed of learning as well as the accuracy of classification.

### 1 はじめに

近年、ディープラーニングをはじめとしたパターン認識の実用化が活発化しているが、その一方でその膨大な消費エネルギーが問題となっている。より省電力でパターン認識を行えるような需要が増しており、その期待に応えるものとして物理リザーバーコンピューティング (Physical Reservoir Computing: PRC, 物理 RC) という物理現象のダイナミクスを利用したニューロ的な計算手法が注目されており、様々な物理現象を用いて試みられている。そのうちのひとつとしてスピン波を用いたリザーバーコンピューティングの概念とその構成、基礎的な検証が提案されている。本研究ではこのスピン波リザーバーコンピューティングデバイスの物理実装に向けて、このデバイスの性質をシミュレーション上で検討する。

本資料では、まずスピン波によるリザーバーコンピューティング・チップについて、その波動の複雑な伝搬の様子を観測する。今回、入力信号としては正弦波、矩形波を採用し、これらを分類するような学習を考える。次に、時間的に伝搬する波動が、空間的にどこに有用な情報を形成するかを調べる。リザーバーの出力端子を仮想的に多数用意し、精細にチップ全体を覆うように配置して、それに結合させる出力ニューロンのシナプス結合の重みを調査する。その結果、2つの入力がかうまく相互作用する箇所では荷重の絶対値が大きくなる。すなわち、そこに有用情報が集まることが確認される。スピン波リザーバーでは、このような学習が自然に行われる。この分布によって、今回のタスクに対して必要な出力抽出端子の大きさは、50 nm 程度であり現実的な値であることを確かめる。そして 64 個という現実的な個数の出力を持ったデバイスで学習を行ったところ、うまく学習が行われたことを報告する。このとき出力電極はランダムな位置に配置する。また 8、16、32 個の出力電極の個数を用いて同様の学習を行い、出力電極の個数と学習の早さ、精度との関係を調べる。




fig.1 Concept of Echo State Network(ESN).




fig.2 Concept of Physical Reservoir Computing(PRC) [2]. You can see reservoir neurons in reservoir are replaced by physical systems/devices comparing with ESN(fig.1).

## 2 背景

### 2.1 リザーバーコンピューティング

リカレントニューラルネットワーク (RNN) は再帰的な構造を持つニューラルネットワークであり、その構造から、パーセプトロンやディープラーニングで用いられるような層状のニューラルネットワークとは異なり、時系列データをそのまま処理することができる。しかし RNN は層状ニューラルネットワークに比べニューロン間の結合が多くなり、それらの間の結合荷重を勾配法などによって全て更新しようとするとうニューロン数に対して莫大な計算量が必要になってしまうという問題があった。そこで 2001 年に Jeager によって提案された RNN が Echo State Network(ESN) [1] であり、リザーバーコンピューティングの主要なモデルとなっている。

ESN は図 1 に示されるようなニューラルネットワークであり、通常の RNN とは異なり入力層の結合荷重  $W^{in}$  とリカレントな部分の結合荷重  $W$  はランダムな値で固定されており、読み出し部の結合荷重  $W^{out}$  のみを可変し、学習によって更新するというものである。ニューロンがリカレント構造をなしている部分はリザーバー (Reservoir) と呼ばれる。リザーバーはため池という意味で、この部分に過去に inputs された情報がたまることに由来している。ESN においてリザーバー内の各ニューロンの状態は以下の式のように表される。

$$\mathbf{x}(n) = f(W^{in}\mathbf{u}(n) + W\mathbf{x}(n-1)), \quad (1)$$

ここで  $n$  は離散時間を表しており、 $\mathbf{x}$  はリザーバーの内部状態ベクトル、 $\mathbf{u}$  はリザーバーの入力行列、 $W$  はリザーバーの結合荷重行列、 $W^{in}$  は入力層の荷重行列である。ESN では出力層の荷重のみが可変なので、 $W$  と  $W^{in}$  はリザーバーごとに固有の、固定された行列となる。 $f$  はニューロンの活性化関数であり、何らかの非

線形関数が用いられる。 $f(x) = 1/(1 + \exp(-x))$  (シグモイド関数) や、 $f(x) = \tanh(x)$  がよく用いられる。 $\mathbf{x}(n)$  を定める式 (1) の項に  $\mathbf{x}(n-1)$  が入っていることが、ESN が時系列データを扱っていることを意味している。出力は次のように表される。

$$\mathbf{y}(n) = f_{out}(W^{out}\mathbf{x}(n)), \quad (2)$$

$\mathbf{y}(n)$  は  $n$  における出力ベクトル、 $W^{out}$  は出力層の結合荷重である。また  $f_{out}$  は出力ニューロンの活性化関数で任意の関数であり、線形和でも十分機能することが多い。 $W^{out}$  は  $W$  や  $W^{in}$  と異なり学習によって変化する。具体的には、ムーア・ペンローズの擬逆行列などを用いて求めることができる。或いはオンラインに荷重を更新したい場合や学習用データが膨大な場合は、教師出力と実際の出力の二乗誤差の和やクロスエントロピーをコスト関数とし、そのコスト関数を最小化するような方向に  $W^{out}$  を変化させるような方法がよく用いられ、これは勾配法と呼ばれている。

### 2.2 物理リザーバーコンピューティング

リザーバーコンピューティングにおけるリザーバー内のふるまいを、物理的なダイナミクスを用いて置き換えることでリザーバーコンピューティングを物理的に実装しようとする試みが近年活発に行われており、これらは物理リザーバーコンピューティング (PRC、物理 RC) と呼ばれている (図 2)。物理 RC は現行のフォンノイマン型のコンピュータを用いたパターン認識とは異なり、物理的に直接パターン認識を行っているという点で従来のものとは一線を画す、新しい視点の計算法である。リザーバーコンピューティングを行う上では物理 RC はフォンノイマン型のコンピュータより早く、省エネルギーでパターン認識が行える可能性があり注目されている。またリザーバーのランダム性を逆手にとって、デバイスの製造に精度が求められない、「作りこま

ないデバイス」を設計することも可能である [3]。一般に、非線形性、短時間記憶性、の二つの性質を兼ね備える物理的ダイナミクスは、物理リザーバーコンピューティングに応用することができる可能性があり、光学 RC [4, 5]、電子 RC [6]、といった実用化を念頭に置いたものから、タコ足ソフトロボット [7]、バケツの水 [8] といったユニークなものまで様々な物理的ダイナミクスを利用して物理リザーバーコンピューティングが行われている [2]。

### 2.3 スピン波リザーバーコンピューティング

物理 RC の一つに、スピン波を利用するリザーバーコンピュータの概念とその構成、基礎的な検証も報告されている [9, 10]。そこでは、方形波として時間的に変化するベースバンド信号を入力信号とした。そしてその方形波の継続時間を推定するタスクを設定し、これに成功した。このスピン波リザーバーコンピューティングデバイスは、波動現象を利用している。すなわち、ヒステリシス、非線形性、空間的な非対称性などを利用するとともに、波動としての分散特性も利用できる。この場合、ヒステリシスは入力信号と入力端との相互作用が、入力端の状態に依存していることを意味するとともに、伝搬もヒステリシスを有している。非線形性は、波の性質が波動の振幅に依存していること、たとえば干渉の際に波動が単なる重ね合わせではない値をとり、また高次周波数成分を発生することにつながる。また非対称性は、2次元または3次元的に波動が伝搬する際に異方性があることを指す。そこでは、スピン波の時空間的な特性が直接にリザーバーの機能の豊かさを規定する。

先行研究 [9] では基本的な構成、検証にとどまっており、また計算方法は、得られた振幅の値を時間方向に展開してから計算を行うため、2次元波であることによる空間的な情報を十分に利用していない。そこで本研究では現実的なデバイス構成、リアルタイム処理を行えるデバイスを念頭に置きシミュレーションを行う。

## 3 スピン波リザーバーの構成とタスク

### 3.1 物理的な構成

図 3 は素子の基本構造の概念図である。物理的な詳細は、先行研究と同様のものを用いた [9, 10]。簡単には、入力電極に電圧を加えることにより、ME 結合層で生じる ME 結合によって、ガーネットフィルムのスピンの波動を誘起することができる。その波動はフィルム内を伝搬する。その際、波動は異方性を伴いながら伝搬したり、非線形性を伴いながら干渉したりする。また入力電極やフィルムでの波動伝搬は、新たな信号




fig.3 Basic structure of spin-wave reservoir computing device [9].




fig.4 Structure of the network.

に対しヒステリシスを持つ。このような特性から、スピン波自体が時系列入力信号を複雑な時系列信号に変換する。これがスピン波リザーバーの効果的な動作である。このような複雑なスピン波動を入力と同様に出力電極で ME 結合によってピックアップし、出力信号を得る。

図 4 に本論文での解析のためのフィルムの大きさと 2つの入力電極を示す。ここで、2つの入力端子を設置するのはスピン波の非線形な干渉を利用するためである。干渉を利用する場合としない場合の性能の評価は先行研究でなされている [9, 10]。

また各定数は文献 [9] と同じものを用いた。膜厚 100 nm は z 軸方向のメッシュ間隔は 50 nm である。ダンピング定数  $\alpha=0.001$  (ガーネット薄膜) または 1 (ダンパー)、飽和磁化  $M_S = 100$  kA/m、交換ステイフネス定数  $A_{EX} = 3.6 \times 10^{-12}$  J/m、z 軸方向の今回想定した最大電圧を印加したときの磁気異方性定数  $K_U^L$  (1kJ/m<sup>3</sup>)、印加しないときの時期異方性定数  $K_U^H$  (10kJ/m<sup>3</sup>)、立方異方性定数  $K_C=0$ 、シミュレー

シオン温度  $T=0$  K とした。これらの物理的な詳細は実際のガーネット ( $\text{TM}_3\text{Fe}_5\text{O}_{12}$ ,  $\text{Y}_3\text{Fe}_5\text{O}_{12}$ ) を想定したものであり、これもまた文献 [9] に倣ったものである。

### 3.2 正弦波/矩形波分類タスク

タスクには正弦波/矩形波の分類を採用する。リザバーコンピューティングを含む RNN の特徴として時系列データをそのまま扱うことができるという特徴があり、時系列処理が正弦波/矩形波分類はこの特徴を生かせるタスクである。2 端子にそれぞれ、周波数  $f = 2.5$  GHz (周期  $T = 0.4$  ns) の正弦波、矩形波を入力する。ただし、今回は理想的な矩形波の代わりに式 (3) のように第 4 項までフーリエ級数展開した矩形波を用いた。

$$f_{\text{square}}(t) = \cos\left(\frac{2\pi t}{T}\right) - \frac{1}{3}\cos\left(\frac{3 \times 2\pi t}{T}\right) + \frac{1}{5}\cos\left(\frac{5 \times 2\pi t}{T}\right) - \frac{1}{7}\cos\left(\frac{7 \times 2\pi t}{T}\right) \quad (3)$$

これは、現実的に入力される電圧は理想的な矩形波よりも立ち上がりがなまったものと考えられるからである。2 端子には同じ波形を入力し、正弦波を入力したときは"0"が、矩形波が入力されたときは"1"が出力ニューロンから出力されるよう学習を行う。縦軸の入力信号に対応して変調される物理量は、magnetocrystalline anisotropy constant  $K_u$  であり、電圧入力によってこれを等価的に変化させる。なお、以下のスピン波解シミュレーション析にはシミュレータ MuMax3 を用いた [11]。x-y 平面内の空間メッシュは 10 nm 四方、時間ステップは 0.01 ns とした。

### 3.3 学習方法

図 4 にリザバーニューラルネットワークの全体の構成も示す。リザバー出力信号は、出力ニューロンの入力信号でもある。ここでは出力電極の大きさをシミュレータのメッシュ一つ分と仮定した。これらのリザバー出力 (信号  $\mathbf{x}$ ) を前処理の後、出力ニューロンに、シナプス結合 (荷重  $\mathbf{w}$ ) を介して供給する。ニューロンには  $f(u) = (1/(1 + \exp(-u)))$  型の非線形活性化関数を仮定し、出力信号を出力する。可変閾値も準備している。

本解析では、場所  $\mathbf{r}$  でのニューロン出力の包絡線振幅を観測する。場所  $\mathbf{r}$ 、フレーム  $n$  でのリザバー出力ベクトル  $\mathbf{x}(\mathbf{r}, n)$  は、スピン波の振幅の時系列データ  $s_x(\mathbf{r}, n)$  から次のように求められる。

$$\mathbf{x}(\mathbf{r}, n) = \text{Amp}(s_x(\mathbf{r}, n) - s_x^{\text{offset}}(\mathbf{r})) \quad (4)$$

ただし  $\text{Amp}(\cdot)$  はスピン波の振幅を表し、今回のシ

ミュレーションではヒルベルト変換したものの絶対値を用いた。現実的にはアナログ的にダイオードによる整流を行う。学習用データ全体に対して出力値  $y(n)$  と正弦波/矩形波に対応する教師信号  $\hat{y}(n)=1$  あるいは 0 によって、ミニバッチ学習を行う。ミニバッチ学習は比較的多くのデータを扱う学習を行う際に用いられる学習方法であり、次のような手順で学習が行われる。まず、学習に用いる  $N$  個のデータセットを  $N/N_{\text{mini}}$  個の、 $N_{\text{mini}}$  個のデータからなるデータセットに分ける。次に、あるミニバッチのデータ全てに対して次式のように荷重  $\mathbf{w}$  を  $\mathbf{w}_{\text{new}}$  に更新する。

$$\Delta \mathbf{w} = -\frac{\eta}{N_{\text{mini}}} \sum_{n=1}^{N_{\text{mini}}} (y(n) - \hat{y}(n)) f'(\mathbf{w} \cdot \mathbf{x}) \mathbf{x} \quad (5)$$

$$\mathbf{w}_{\text{new}} = \mathbf{w} + \Delta \mathbf{w} \quad (6)$$

ここで  $\eta$  は学習係数である。 $f'(\cdot)$  は非活性関数  $f(u) = (1/(1 + \exp(-u)))$  を  $u$  で微分したものである。なお、 $\mathbf{w}, \mathbf{x}$  はバイアス成分も含み表記している。同様の操作を  $N/N_{\text{mini}}$  個のデータ全てに対して行う。学習データをすべて用い、一周学習することを 1 エポックと数える。

## 4 正弦波矩形波分類タスクの実験結果

### 4.1 スピン波伝搬の様子

図 5 は正弦波、図 6 は矩形波を 2 端子に入力したときのスピン波の伝搬の様子である。今回用いた周波数は  $f = 2.5$  GHz であり、フレーム 1 枚は 0.01ns であるから、40 フレームで入力波の 1 周期である。スピン波は 10GHz 程度の強磁性共鳴 (FMR) 周波数と呼ばれる基本周波数を持っており、その周波数で赤と青が入れ替わっている。入力信号正弦波を入力したときと矩形波を入力したときでスピン波の干渉の様子が異なっていることがわかる。図 7 は図 5、図 6 のようなスピン波の振幅をあるフレームについて式 (4) のように前処理をして求めた信号であり、またこれは出力ニューロンの入力  $\mathbf{x}$  に使用される値である。

### 4.2 有用情報の分布

まずガーネット薄膜上の有用情報分布を調べるために、すべてのメッシュに仮想的に出力電極が配置されているとして学習を行った。

図 8 は学習後の荷重分布である。赤い部分は正、青い部分は負の荷重であり、その色が濃いほどその絶対値が大きいことを表している。同じ色の部分が集まっている場所は同様の特徴量が得られる場所と考えることができる。中央付近に縞状に荷重の絶対値が大






fig.5 Spin-wave propagation when we feed the sinusoidal wave to the two input electrodes. ( $T=0.4\text{ns}$ )

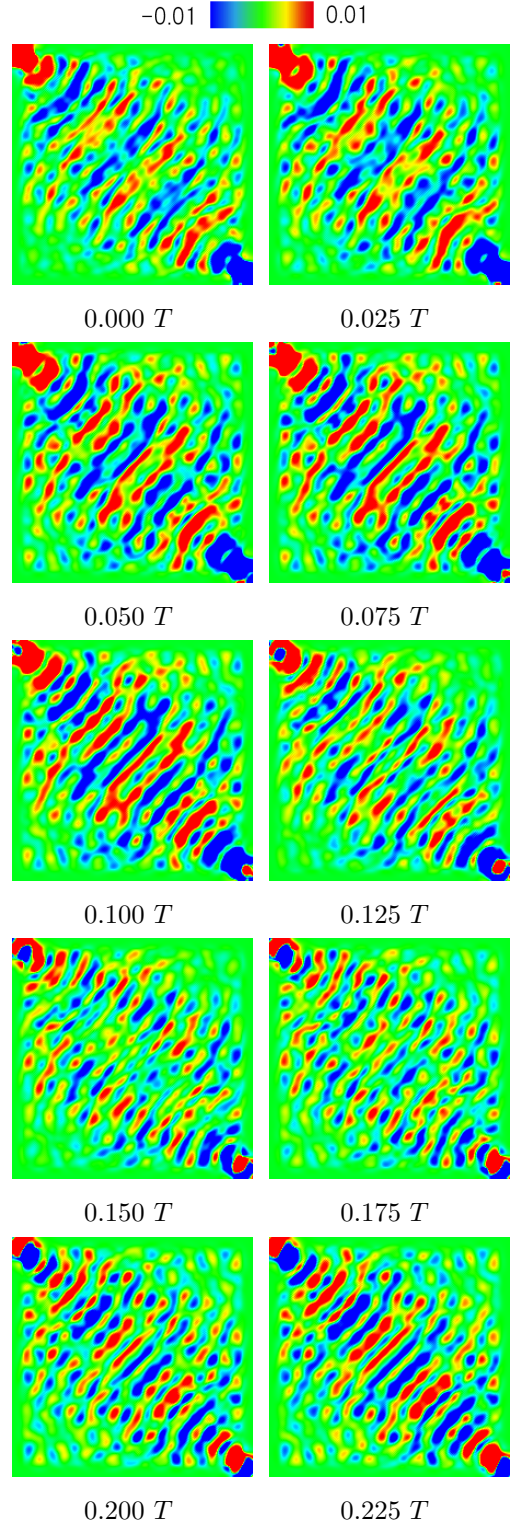


fig.6 Spin-wave propagation when we feed the square wave to the two input electrodes. ( $T=0.4\text{ns}$ )




fig.7 Amplitude of the spin wave at 0.000 T when we feed (a)sinusoidal and (b)square waves to the two input electrodes.




fig.8 Distribution of synaptic weights at 300 epoch learning. (1 pixel= $10 \times 10 \text{ nm}^2$ )

きい部分が分布していることが分かり、またこの幅は 50 nm 以上であるように見て取れる。つまり出力電極の大きさとしては今回のタスクでは数十 nm が適切であると考えられる。

#### 4.3 現実的な出力端子個数での学習

次に現実的なシミュレーションとして有限個の出力をガーネット薄膜上のランダムな位置に設定し、同様のタスクを行なった。ネットワークの概念図が図 4 で




fig.9 An example of randomly selected output electrodes when the number of electrodes is 64. (1 pixel= $10 \times 10 \text{ nm}^2$ )

ある。64 個の電極を利用するときランダムに選んだ電極の場所の例が図 9 である。入力電極上には実際には出力電極を配置することができないため、位置が選択されないようにした。

64 個の電極を使用した時の結果が図 10 である。正弦波を入力している時間帯は 0、矩形波を入力している時間帯は 1 に近い出力が得られており、適切に分類できていることがわかる。入力信号が切り替わる部分で中間的な出力が出ているのは、リザーブが時系列データを扱っていることを表している。またこのときの、エポック数に対する目標出力と実際の出力の RMSE を示したものが図 11、検証データの正解数を示したものが図 12 であり、学習がうまく進んでいることがわかる。なお、正解数は出力が 0.5 未満のときは 0(正弦波)、0.5 以上のときは 1(矩形波)と判定されたものとした。

8、16、32、64 個のランダムに選択した電極を利用して学習を行った場合の、出力と教師信号の二乗誤差 RMSE を示したのが図 13 である。ランダムに選択した場合の RMSE や正解数はばらつきが大きいためそれぞれ 10 回ずつ学習を行い、それらの分散をエラーバーに示した。図 13 から電極数が多いほど学習が早くなっていることがわかる。これは図 8 における有用情報が得られる場所に電極が配置される確率が高まるからだと考えられる。実行するタスクがある程度決まったものであれば、図 8 を利用して有用情報が多く得られる場所に出力電極を配置することで、性能が高




fig.10 Resulting neural output after learning (64 output electrodes, 2000 epoch).




fig.11 RMSE against epoch (64 output electrodes, 2000 epoch).

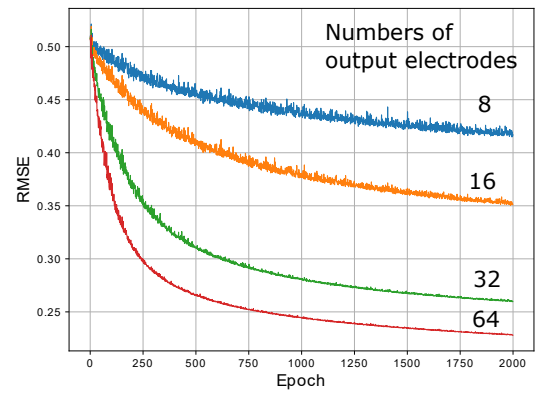


fig.13 RMSE when the number of output electrodes are changed.




fig.12 Correct number of the classification (64 output electrodes, including errors caused by switching of the input signals).

いデバイスを作成できる可能性がある。ただしその場合、未知の入力への汎化能力が低下すると考えられるので、配置場所にはある程度のランダム性はあったほうが望ましいと考えられる。

## 5 結論と今後の方針

今回、まず正弦波矩形波の波形分類タスクについてスピン波の伝搬や振幅の分布を観察し、リザーバーコンピューティングに必要とされるような複雑な応答が得られたことを確認した。次に、仮想的に全メッシュにくまなく出力電極を配置し学習を行い、荷重分布から得られる有用情報分布を確認することで、理想的な出力電極の大きさが数十 nmであることを確認した。そして、現実的に 64 個の出力電極という実装可能な構成を持ったスピン波リザーバーが、波形分類タスクを行うことができることをシミュレーション解析上で示した。また 8 個、16 個、32 個の出力電極でも同様の分類の学習を行い、この個数の範囲では出力電極は多いほど良い、ということがわかった。以上の結果

は、現実的な構成のスピン波リザーバーが実用的タスクを行えるということを示し、また物理的実装をする際の出力電極の大きさ、個数を決める指針となる。

今後の方針としてはこのデバイスを始めとした二次元波を用いたリザーバーコンピューティングの数理モデルを構築し、ESN の必要条件である Echo State Property やリザーバーの複雑性などに関連付けて、性能を向上させるための条件を定式化していく予定である。

## References

- [1] H. Jaeger, “The “echo state” approach to analysing and training recurrent neural networks-with an erratum note,” *Bonn, Germany: German National Research Center for Information Technology GMD Technical Report*, vol. 148, no. 34, p. 13, 2001.
- [2] G. Tanaka, T. Yamane, J. B. Héroux, R. Nakane, N. Kanazawa, S. Takeda, H. Numata, D. Nakano, and A. Hirose, “Recent advances in physical reservoir computing: A review,” *arXiv preprint arXiv:1808.04962*, 2018.
- [3] 廣瀬 明 and 中野 大樹, “リザーバーコンピューティングの今後の展開,” *電子情報通信学会誌*, vol. 102, no. 2, pp. 147–149, February 2019.
- [4] Y. Paquot, F. Duport, A. Smerieri, J. Dambre, B. Schrauwen, M. Haelterman, and S. Massar, “Optoelectronic reservoir computing,” *Scientific reports*, vol. 2, p. 287, 2012.
- [5] L. Larger, A. Baylón-Fuentes, R. Martinenghi, V. S. Udaltsov, Y. K. Chembo, and M. Jacquot, “High-speed photonic reservoir computing using a time-delay-based architecture: Million words per second classification,” *Phys. Rev. X*, vol. 7, p. 011015, Feb 2017. [Online]. Available: <https://link.aps.org/doi/10.1103/PhysRevX.7.011015>
- [6] Y. Yi, Y. Liao, B. Wang, X. Fu, F. Shen, H. Hou, and L. Liu, “Fpga based spike-time dependent encoder and reservoir design in neuromorphic computing processors,” *Microprocessors and Microsystems*, vol. 46, pp. 175 – 183, 2016. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0141933116300060>
- [7] K. Nakajima, H. Hauser, T. Li, and R. Pfeifer, “Information processing via physical soft body,” *Scientific Reports*, vol. 5, p. 10487, 2015.
- [8] C. Fernando and S. Sojakka, “Pattern recognition in a bucket,” in *Advances in Artificial Life*, 2003, pp. 588–597.
- [9] R. Nakane, G. Tanaka, and A. Hirose, “Reservoir computing with spin waves excited in a garnet film,” *IEEE Access*, vol. 6, pp. 4462 – 4469, 2018.
- [10] —, “Demonstration of spin-wave-based reservoir computing for next-generation machine-learning devices,” in *International Conference on Magnetism (ICM) 2018 San Francisco*, July 2018, pp. 26–27.
- [11] A. Vansteenkiste, J. Leliaert, M. Dvornik, M. Helsen, F. Gracia-Sanchez, and B. Van Waeyenberge, “The design and verification of MuMax3,” *AIP Advances*, vol. 4, no. 10, October 2014.